FIAP

SUSTENTAÇÃO DE CREDIT SCORING

Contrato de dados, detecção de drift, observabilidade e governança para um modelo que erra sem avisar — End-to-End

Scikit-Learn | Pandera | Evidently | MLflow | Prometheus | Grafana | Loki · Tempo | fairlearn

C R E D I T S C O R I N G O B S E R V A B I L I T Y



SITUAÇÃO · STAR : S

O Problema

Contexto

- Uma fintech tem um **modelo de credit scoring em produção**. A economia muda — inflação, novos perfis de cliente — e a diretoria desconfia que o modelo **decide errado sem ninguém perceber**: a degradação silenciosa
- Requisitos da fase: **contrato de dados** que bloqueie lotes inválidos, **simulação de drift** com Evidently, **observabilidade** (logs, métricas, MLflow, alertas) e **governança** (LGPD, vieses, causalidade)
- O modelo é simples de propósito: uma **Regressão Logística** treinada no Lending Club. O difícil não é o modelo — é **saber quando ele parou de funcionar**

2,26 M

empréstimos · 151 colunas — All Lending Club Loan Data (2007–2018)

1,35 M

com desfecho conhecido (pago × charged off) · 19,98% de inadimplência

AUC 0,69

modelo V2 congelado, threshold 0,20 — o suficiente para a história ser sobre monitoramento

OBJETIVO: saber quando o modelo erra, por quê e o que fazer — antes que a diretoria descubra pelo prejuízo

TAREFA · STAR : T



Nossa Solução

1. **Referência × produção** separadas (80/20, seed 42) e modelo V2 **congelado** com threshold versionado
2. **Contrato Pandera** sobre as 23 features + regras de lote — **bloqueia antes da inferência**
3. **Simulação de 7 meses** com intervenções conhecidas: entradas alteradas, depois rótulos alterados
4. **Detecção**: PSI + KS por feature, Evidently por mês, **controle de performance fora do treino** com IC bootstrap
5. **Gate** OK / WARN / ALERT que **recomenda** a ação — e nunca retreina sozinho
6. **Observabilidade** (MLflow · Prometheus · Grafana · Loki · Tempo · 10 alertas com runbook) e **governança** LGPD, fairness e análise causal

Metas

Critério de dados

Nenhum lote inválido pontuado

Critério de detecção

Separar quem chega de o que acontece com o mesmo perfil

Reprodutibilidade

`make` do clone ao resultado · 199 testes · CI

Governança

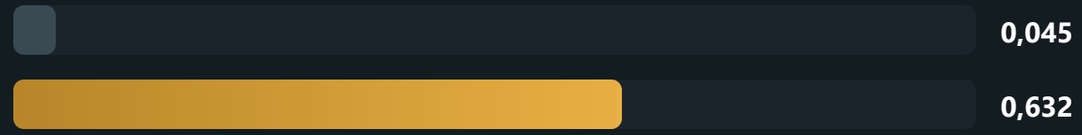
Cada afirmação do README com teste ou configuração por trás

AÇÃO · STAR : A



Modelo V2 — Simples de Propósito

Recall da classe inadimplente — pool de produção (269.620 registros que o modelo nunca viu)



🏆 Por que o threshold, e não um modelo maior

A AUC é a mesma nas duas versões (**0,694**): o que muda é a **regra de decisão**. A V1 com corte 0,50 aprovava quase todo mundo e só pegava **4,5%** dos inadimplentes. Selecionamos o threshold na validação interna maximizando **F2** com precision mínima 0,30, e o modelo passou a negar os **63%** de inadimplentes que importam. Pipeline completo (imputação, RobustScaler, one-hot, Regressão Logística) em **23 features**, com o threshold versionado nos metadados e aplicado pelo `registry.load_model()`.

300 mil

amostra estratificada de treino · validação interna de 20% · seed 42

1,08 M / 270 mil

referência × pool de produção: o split é garantido no `make prepare`

O modelo é o cenário, não o protagonista — a história é sobre descobrir quando ele deixa de funcionar

FIAP



AÇÃO · STAR : A

Contrato de Dados — Nada Inválido É Pontuado

lote mensal
parquet / csv
10 mil linhas

→

regras de lote
volume mínimo · cliente duplicado · coluna de vazamento

→

schema Pandera
23 features finais
tipos, faixas, categorias

→

modelo V2
score + decisão
threshold 0,20

→

bloqueado?
quarentena 30 dias
relatório · exit 2

2.100
linhas do lote corrompido de demonstração

8
violações bloqueantes — cada regra com camada, severidade e contagem

0
predições: o modelo nunca é chamado; os 7 meses seguintes continuam normalmente

⚠ Regras rígidas que bloqueiam o lote inteiro

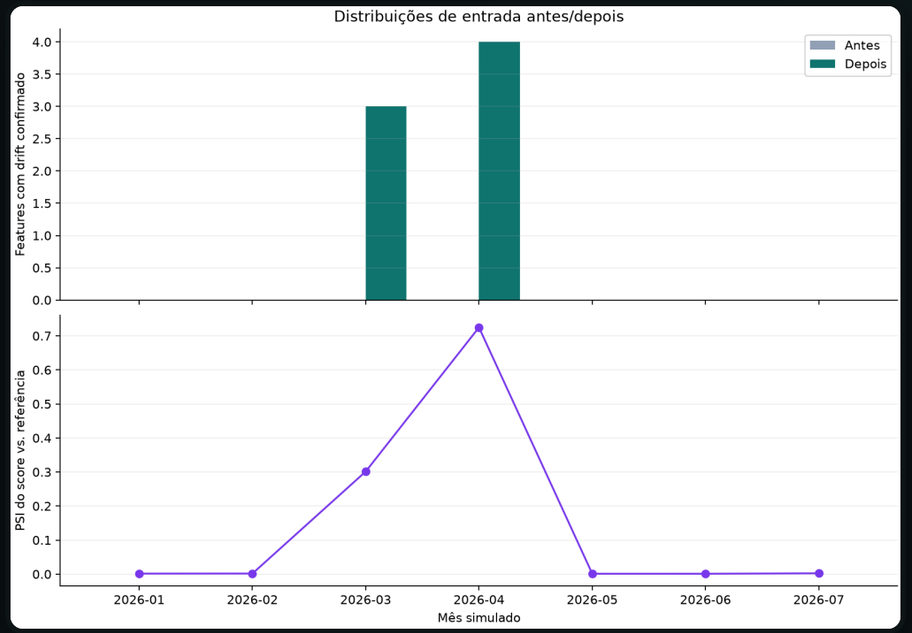
Renda obrigatória (`annual_inc` não nula) · **FICO entre 300 e 850** · **valor do empréstimo positivo** · **prazo em {36, 60}** · **cliente sem duplicata** no lote · coluna inesperada como `loan_status` (vazamento de rótulo) · coerência entre tempo de emprego ausente e seu indicador. Não há predição parcial: lote bloqueado vai inteiro para `data/quarantine/`, com `customer_id` mascarado no relatório, e é descartado em 30 dias (`make purge-quarantine`).

make demo-contract: saída BLOQUEADO, código 2, quarentena — provado por script, não por slide



AÇÃO · STAR : A

Simulação e Detecção de Drift



Features com drift confirmado (acima) e PSI do score (abaixo) — execução de referência de 21/10/2026

Sete meses, três fases

- **Jan–fev · estável**: 10 mil registros por mês, sem intervenção
- **Mar–abr · entradas alteradas**: renda −35%, DTI +80%, rotativo +25 p.p., FICO −30 (intensidade máxima); rótulos preservados
- **Mai–jul · rótulos alterados** por segmento (FICO, prazo); X e scores idênticos

Detecção por feature, sem cenário

- Numéricas: **PSI > 0,25 e KS D > 0,10** ao mesmo tempo; categóricas: **JS ≥ 0,10**
- Confirmadas: **3/23** em março, **4/23** em abril, **0** nos demais
- Um **HTML Evidently** por mês, com a recomendação do gate no topo

O drift de entrada foi confirmado antes de qualquer queda de performance — e o PSI do score mostrou o deslocamento das decisões

AÇÃO · STAR : A



Gate — Decide Só com Métricas

Mês	AUC	PSI score	Aprovação	Drift	Gate · ação
2026-01	0,7051	0,0015	59,4%	0/23	OK observar
2026-02	0,7035	0,0017	59,5%	0/23	OK observar
2026-03	0,6963	**0,3014**	**35,4%**	**3/23**	WARN reforçar monitoramento
2026-04	0,6995	**0,7248**	**24,5%**	**4/23**	WARN reforçar monitoramento
2026-05	**0,6181**	0,0011	59,3%	0/23	ALERT avaliar retreino
2026-06	**0,5993**	0,0010	59,2%	0/23	ALERT avaliar retreino
2026-07	**0,5589**	0,0024	58,3%	0/23	ALERT avaliar retreino

AUC do controle reservado (30 mil registros fora do treino): 0,6974 · limite de queda: 0,05 absoluto

Como o gate decide

- **WARN**: drift confirmado sem queda de AUC acima de 0,05 → investigar entradas, acompanhar Brier e aprovação
- **ALERT**: queda > 0,05 **com o IC 95% inteiro acima do limite** (bootstrap, 200 reamostragens), ≥ 500 rótulos e 90% de cobertura
- Sem drift marginal + AUC degradada → **suspeita de concept drift**, não prova

Nunca retreina sozinho

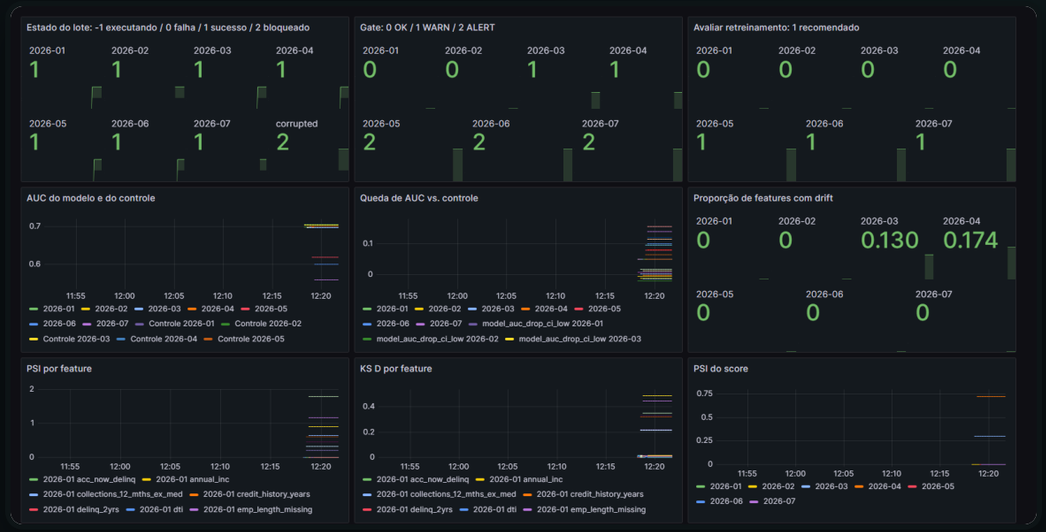
A saída é uma **recomendação** para revisão humana — igual no JSON, no HTML Evidently, no MLflow e nas métricas do Prometheus.

AUC estável não significa ausência de impacto: em abril a aprovação caiu 35 p.p. com a AUC intacta



AÇÃO · STAR : A

Observabilidade — Métricas, Logs e Traces



Dashboard "Observabilidade - Credit Scoring", provisionado ao subir a stack — estado dos 8 lotes, gate 0/1/2, retreino recomendado, AUC vs. controle, drift, aprovação e Brier

20

painéis: lote, gate, AUC, PSI/KS, aprovação, Brier, duração/CPU/RSS por estágio, alertas, logs

10

regras de alerta, cada uma com `runbook_url` para "significa · investigar · ação"

1 + 1

run MLflow e trace OpenTelemetry por lote; `trace_id` no log, no run e no painel

make monitor
validate → score → drift → performance → gate

→

Métricas
Pushgateway → Prometheus → Alertmanager

→

Logs
structlog → Alloy → Loki · `customer_id` mascarado

→

Traces
OpenTelemetry → Tempo

→

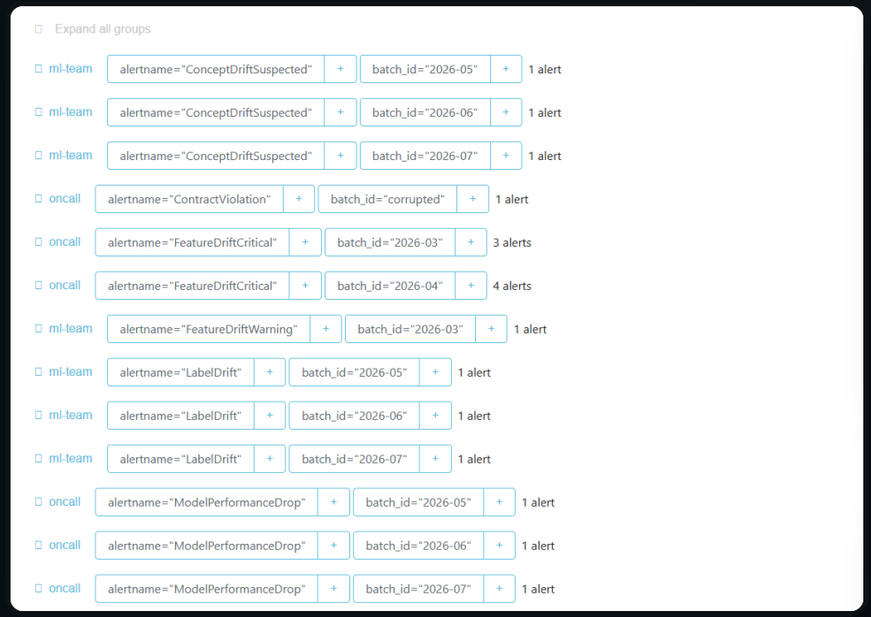
Grafana + MLflow
dashboard · run com HTML/JSON

Bloqueio esperado não é falha: status 2 no lote, nenhuma AUC publicada, e o pipeline segue para o mês seguinte

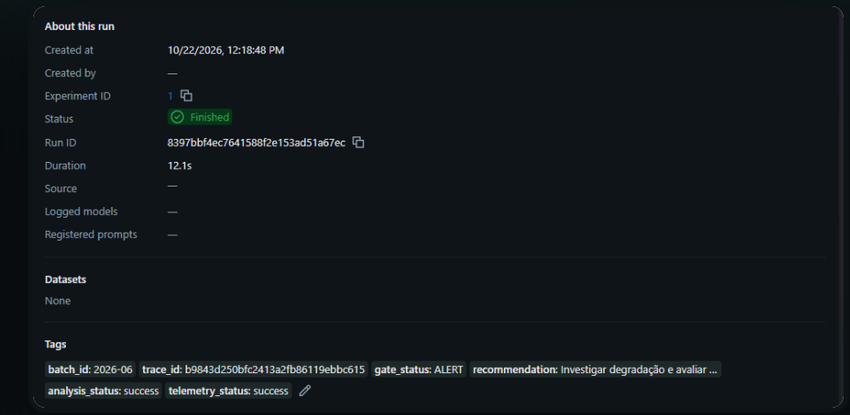
AÇÃO · STAR : A

Alertas com Runbook, Runs e Traces

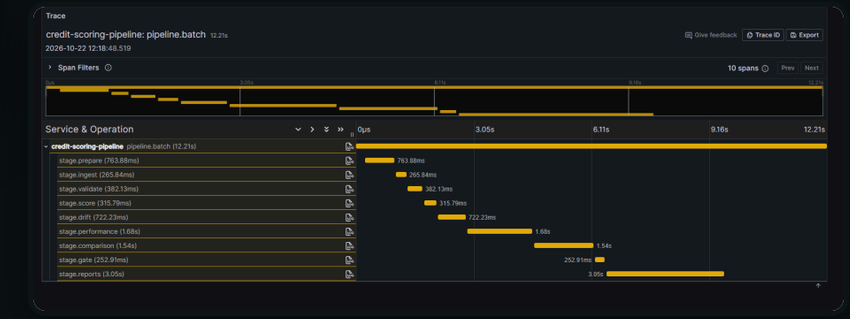




Alertmanager: 21 alertas agrupados por regra e lote — contrato no `corrupted`, drift em 03/04, queda de AUC, concept drift, label drift e retreino em 05–07



MLflow: run `batch_2026-06` com tags `gate_status: ALERT`, `trace_id` e a recomendação do gate



Tempo: um trace por lote, um span por estágio — do `prepare` ao `reports`

Um alerta sem runbook é só barulho: as 10 regras apontam para "significa · investigar · ação" no monitoring-plan.md

AÇÃO · STAR : A



Governança — LGPD e Fairness

Proteção de dados por construção

- **Pseudonimização**: `id` → SHA-256 com sal fora do git; o original é descartado
- **Minimização**: só **27 das 151 colunas** são lidas; texto livre, CEP e URL nunca entram; estado vira região e é descartado
- **Base legal**: Art. 7º, X (proteção do crédito) + Lei 12.414; **Art. 20** — explicação pelos coeficientes e revisão humana perto do threshold
- **Retenção**: quarentena 30 dias · logs, métricas e traces 90 dias
- Telemetria de MLflow, Evidently e cia. **desligada por padrão**

Região	Aprovação	FPR	TPR
Midwest	59,1%	35,2%	63,8%
Northeast	58,6%	35,8%	63,4%
South	59,6%	34,8%	62,2%
West	58,5%	36,2%	64,1%

Viés medido, mitigação avaliada e não adotada

Região (proxy de raça e renda) **não é feature**. Razão de impacto desigual **0,983** no pool e entre **0,875 e 0,977** nos lotes — sempre acima da regra dos 4/5. Thresholds por região ficariam em 0,198–0,203: ganho desprezível e tratamento diferenciado por proxy (Art. 6º, IX).

Governança não é um capítulo do README: é hash com sal, colunas que nunca são lidas e um comando que apaga a quarentena



AÇÃO · STAR : A

Análise Causal — Hipóteses e Sensibilidade

DAG de hipóteses (ilustrativo, não estimado)

Choque macro (inflação)

Novos perfis de cliente

→

Renda real ↓ → **DTI** ↑

Rotativo ↑

FICO ↓

→

Default

⇠

Renegociação / aperto de renda
muda P(default | X)

Mês	PSI score	após restaurar	AUC	após restaurar	Diagnóstico
2026-03	0,3014	**0,0008**	0,6963	0,6948	covariate shift
2026-04	0,7248	**0,0009**	0,6995	0,6970	covariate shift
2026-05	0,0011	0,0010	0,6181	**0,6184**	concept drift?
2026-06	0,0010	0,0011	0,5993	**0,5993**	concept drift?
2026-07	0,0024	0,0023	0,5589	**0,5589**	concept drift?

O que o teste mostra — e o que não

`make causal` restaura as marginais de renda+DTI, rotativo e FICO para a referência. Em março/abril o **score volta ao normal**; em maio–julho a **AUC não se recupera**. É compatível com as hipóteses, mas é **sensibilidade do modelo congelado**, não prova de causa econômica: isso exigiria dados de intervenção ou desenho quase-experimental.

Sensibilidade organiza hipóteses, não prova causa — o DAG é ilustrativo e o diagnóstico é uma suspeita operacional



RESULTADO · STAR : R

O que Entregamos

8 / 8
lotes com o desfecho esperado: 1 bloqueado, 2 OK, 2 WARN, 3 ALERT

21
alertas recebidos — todos com runbook; nenhum indevido em jan–fev

0
retreinos automáticos — o gate recomenda, a decisão é humana

199
testes com dados sintéticos · CI (ruff + pytest) em todo PR

Requisitos do challenge — todos cumpridos

- Contrato com ≥ 3 regras rígidas + lote inválido bloqueado ✓
- Referência × produção separadas ✓
- Produção com ≥ 2 variáveis alteradas e predições ✓
- Evidently + PSI/KS por feature ✓
- Logs e métricas centralizados · MLflow · dashboard ✓
- Métricas de saúde documentadas + alertas ✓
- LGPD no README: PII, base legal, retenção ✓
- Mitigação de vieses + análise causal ✓

Verificável

- **docs/evidencias/**: execução de referência congelada com **manifesto de hashes** (modelo, dados, fontes, parâmetros)
- `make prepare · train · simulate · analyze · monitor · causal` reproduzem tudo a partir do clone + CSV
- HTMLs Evidently por mês abrem **sem API nem Docker**

Oito lotes, oito desfechos esperados — e cada número deste deck tem um JSON com hash em docs/evidencias/

RESULTADO · STAR : R



Conclusões e Próximos Passos

🧠 Lições do post-mortem (sem culpados)

- **AUC estável não significa ausência de impacto.** Em abril a aprovação caiu 35 p.p. com a AUC intacta: quem detectou foram o PSI do score e a aprovação. A AUC mede ordenação, não decisão.
- **Degradação sem drift exige rótulos.** Em maio–julho nada em X mudou; sem desfechos, nem PSI, nem KS, nem a restauração veriam algo. A política precisa declarar a latência de rótulos que assume.
- **Fairness fora do pipeline não é governança operacional.** Uma razão calculada à mão depois do incidente não protege ninguém durante o incidente.
- **Sensibilidade organiza hipóteses, não prova causa.** E observabilidade precisa guardar *quando*, não só *o quê*.

✅ Entregues

- Contrato + simulação + drift + gate + observabilidade + governança
- Evidências congeladas, model card, ADRs, runbooks, post-mortem

📌 Próximo passo

- SLI de **aprovação** por lote com alerta próprio
- **Fairness por lote** dentro do pipeline mensal
- **Política de retreino**: dados, validação, economia e fairness como guardrail antes de qualquer promoção

Scikit-Learn · Pandera · Evidently · MLflow · Prometheus · Grafana · Loki · Tempo · OpenTelemetry · fairlearn · uv